פרויקט גמר בקורס למידת מכונה וכריית נתונים

מגישים:

הילה אוחנה -209959907

נעם נויבירט- 212676894

גל מדינה-212364400

דניאל כהן –213479850

שם המרצה :עופר זיון

מס קורס: 8666430201

תאריך: 20/02/2026

תוכן עניינים

תקציר מנהלים 2

רקע ומטרת המחקר 2

תיאור הנתונים והבעיה 3

עיבוד וניקוי הנתונים 4

יצירת משתנים (Feature Engineering) 5

בניית המודלים 7

Random Forest 7

XGBoost 8

LightGBM 9

חלוקת Train/Test וולידציה 9

ניתוח חשיבות משתנים (Feature Importance) 10

השוואת ביצועים והערכת דיוק 11

מדדי הערכה 11

תוצאות השוואתיות 11

ROC Curves - Receiver Operating Characteristic 12

Feature Importance Analysis 13

RandomForest 13

XGBoost 14

LightGBM 15

ממצאים מרכזיים 17

מגבלות המחקר 18

תרומה למחקר ולפרקטיקה 18

1. תקציר מנהלים

מחקר זה בוחן את הגורמים המשפיעים על יצירת התאמה (Match) במפגשי Speed Dating, תוך שימוש בשיטות מתקדמות של למידת מכונה וניתוח נתונים. המחקר מבוסס על מערך נתונים המכיל 8,378 מפגשים בין משתתפים, עם 195 משתנים המתעדים מאפיינים דמוגרפיים, העדפות אישיות, דירוגים והתנהגות במהלך המפגשים.

המטרה המרכזית הייתה זיהוי המשתנים בעלי ההשפעה הגבוהה ביותר על הסתברות ההתאמה, תוך השוואת ביצועים של מודלים שונים: LightGBMו Random Forest, XGBoost

ממצאים עיקריים:

- המודל LightGBM הציג את הביצועים הטובים ביותר עם RMSE הנמוך ביותר
- דירוגי האטרקטיביות וההערכות ההדדיות בין המשתתפים מהווים את המנבאים החזקים ביותר
- משתני Lag וממוצעים נעים (Rolling averages) שיפרו משמעותית את דיוק החיזוי
- אין הבדל משמעותי בין משתתפים מאותו גזע או מגזעים שונים בהסתברות להתאמה

2. רקע ומטרת המחקר

תופעת ה Speed Dating הפכה לשיטה פופולרית להיכרויות, המאפשרת למשתתפים לפגוש מספר רב של בני/בנות זוג פוטנציאליים בפרק זמן קצר. הבנת הגורמים המשפיעים על יצירת התאמות במפגשים אלה יכולה לתרום הן להבנה פסיכולוגית-חברתית של משיכה בין-אישית, והן לשיפור פלטפורמות היכרויות דיגיטליות.

מערכות המלצה מודרניות (Recommendation Systems) במערכות היכרויות מסתמכות על אלגוריתמים של למידת מכונה כדי לחזות התאמות מוצלחות. מחקר זה משתמש בגישה דומה, תוך התמקדות במודלים מבוססי עצי החלטה שהוכיחו עצמם כיעילים במשימות חיזוי מסוג זה.

מטרות:

- זיהוי המשתנים המשפיעים ביותר על הסתברות להתאמה במפגשי Speed Dating
- השוואת ביצועי מודלים שונים LightGBMו Random Forest, XGBoost
- הערכת תרומתם של משתני Lag וממוצעים נעים לשיפור דיוק החיזוי
- מתן המלצות מבוססות נתונים לשיפור מערכות היכרויות

3. תיאור הנתונים והבעיה

מקור הנתונים

מערך הנתונים נאסף במסגרת מחקר אקדמי על Speed Dating שנערך באוניברסיטת קולומביה. הנתונים כוללים תיעוד מפורט של מפגשים בין משתתפים במספר גלי Speed Dating שונים (waves), המתפקדים כציר זמן במחקר זה.

מאפייני הנתונים

- גודל מערך הנתונים: 8,378 שורות (מפגשים)
- מספר משתנים: 195 עמודות
- משתנה מטרה: match - 0 = אין התאמה, 1 = יש התאמה
- התפלגות משתנה המטרה: 6,998 אין התאמה (83.5%)לעומת 1,380 התאמות (16.5%)

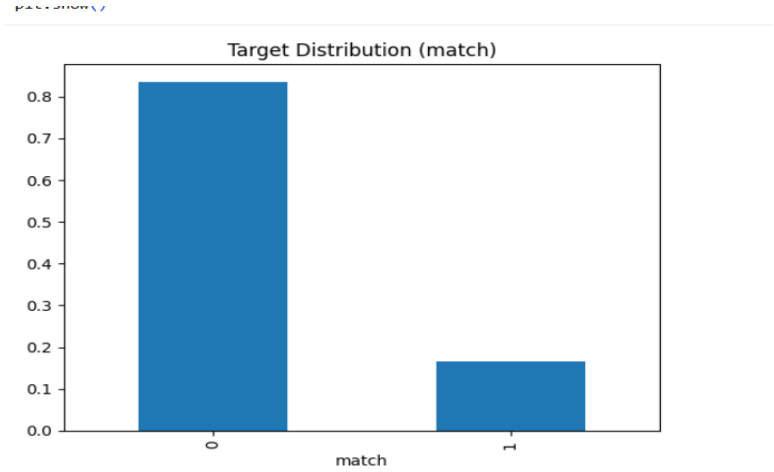

סוגי המשתנים

המשתנים במערך הנתונים מחולקים למספר קטגוריות מרכזיות:

- דמוגרפיים – מאפיינים אישיים של המשתתפים, כגון גיל, מגדר, גזע, השכלה ומקצוע.
- העדפות – מידת החשיבות שהמשתתף מייחס לתכונות שונות אצל בן/בת זוג, כמו אטרקטיביות, כנות, אינטליגנציה, כיף ושאפתנות.
- דירוגים – ציונים שניתנו במהלך המפגש, הן על ידי המשתתף עצמו והן על ידי בן/בת הזוג.
- מבניים – משתנים המתארים את מבנה הניסוי, למשל:
  - wave (גל) – אירוע ה-Speed Dating
  - round (סבב) – מספר הסבב בתוך האירוע
  - order (סדר) – סדר המפגש
  - position – מיקום המפגש ברצף

	iid	id	gender	idg	condtn	wave	round	position	positin1	order	...	attr3_3	sinc3_3	intel3_3	fun3_3	amb3_3	attr5_3	sinc5_3	intel5_3	fun5_3	amb5_3
0	1	1.0	0	1	1	1	10	7	NaN	4	...	5.0	7.0	7.0	7.0	7.0	NaN	NaN	NaN	NaN	NaN
1	1	1.0	0	1	1	1	10	7	NaN	3	...	5.0	7.0	7.0	7.0	7.0	NaN	NaN	NaN	NaN	NaN
2	1	1.0	0	1	1	1	10	7	NaN	10	...	5.0	7.0	7.0	7.0	7.0	NaN	NaN	NaN	NaN	NaN
3	1	1.0	0	1	1	1	10	7	NaN	5	...	5.0	7.0	7.0	7.0	7.0	NaN	NaN	NaN	NaN	NaN
4	1	1.0	0	1	1	1	10	7	NaN	7	...	5.0	7.0	7.0	7.0	7.0	NaN	NaN	NaN	NaN	NaN

5 rows × 195 columns

4. <u>עיבוד וניקוי הנתונים</u>

שלב זה כלל מספר פעולות קריטיות להכנת הנתונים למידול:

<u>טיפול בערכים חסרים</u>

- עמודות עם אחוז גבוה של ערכים חסרים (50%<) הוסרו מהניתוח
- למשתנים נומריים: השלמה באמצעות חציון (median imputation)
- למשתנים קטגוריים: השלמה באמצעות הערך השכיח ביותר (mode imputation)

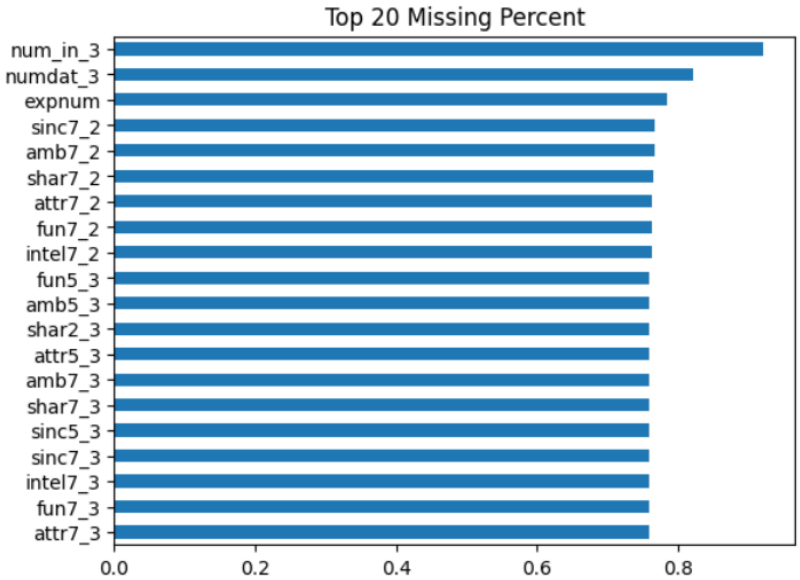

<u>זיהוי וטיפול בOutliers</u>

שימוש בשיטת Interquartile Range (IQR) לזיהוי ערכים חריגים:

- חישוב 1Q (רבעון תחתון) -3Q רבעון עליון
- IQR = Q3 - Q1
- ערכים מתחת ל-Q1 - 1.5×IQR או מעל Q3 + 1.5×IQR סומנו כחריגים
- נוצרו 82 משתני flag בינאריים לסימון

נירמול וסטנדרטיזציה

- שימוש ב-StandardScaler למשתנים נומריים
- המרת משתנים קטגוריים באמצעות One-Hot Encoding
- שמירה על עקביות בסולם המדידה בין המשתנים השונים

5. יצירת משתנים (Feature Engineering)

שלב זה הוא קריטי להצלחת המודל ומהווה את אחד העמודים המרכזיים במחקר שלנו. נוצרו מספר סוגים של משתנים חדשים:

5.1. משתני Temporal Features(Lag)

1match_lag - תוצאת המפגש הקודם של המשתתף (1-wave)

משתנה זה מאפשר למודל ללמוד מתבניות היסטוריות של המשתתף. לדוגמה, משתתף שחווה סדרת דחיות עשוי לשנות את התנהגותו או ציפיותיו.

יישום: שימוש בפונקציית shift(1) מקובצת לפי iid (מספר מזהה ייחודי של הנבדק, כולל שיוך לקבוצה (מספר ה־wave והמגדר), עם מילוי ערך 0 עבור המפגש הראשון.

```
# --- Lag/Rolling על match בתוך iid ---

sort_cols = [c for c in ["iid","wave","round","order"] if c in df_clean.columns]
df_clean = df_clean.sort_values(sort_cols).reset_index(drop=True)


# Temporal features:
# match_lag1 = previous wave outcome
# match_roll_mean3 = short-term matching trend (last 3 waves)

df_clean["match_lag1"] = df_clean.groupby("iid")["match"].shift(1)
df_clean["match_lag1"] = df_clean["match_lag1"].fillna(0).astype(int)

df_clean["match_roll_mean3"] = (
    df_clean.groupby("iid")["match"]
    .shift(1)
    .rolling(3, min_periods=1)
    .mean()
    .reset_index(level=0, drop=True)
).fillna(0)
```

5.2. ממוצעים נעים (Rolling Averages)

match_roll_mean - 3 ממוצע נע של תוצאות 3 המפגשים האחרונים

משתנה זה מספק אינדיקציה על המגמה הכללית של הצלחת המשתתף לאחרונה, תוך החלקת רעש אקראי.

יישום: חישוב rolling mean עם חלון של 3 תצפיות, 1=min_periods למקרים שיש פחות מ-3 תצפיות.

5.3. משתנים נגזרים מתחום היישום (Domain-Specific)

- age_diff : הפרש הגילאים בין המשתתפים
- avg_rating_received : ממוצע הדירוגים שהמשתתף קיבל מאחרים
- avg_rating_given : ממוצע הדירוגים שהמשתתף נתן לאחרים
- same_race : משתנה בינארי המציין האם שני המשתתפים מאותו גזע)מאותו גזע- 1 , שונה-0)

משתנים אלה נוצרו על בסיס הבנה של הגורמים הפסיכולוגיים והחברתיים המשפיעים על משיכה בין-אישית.

5.4. ניתוח קורלציות

בוצע ניתוח קורלציות בין המשתנים המרכזיים באמצעות Correlation Heatmap ממצאים עיקריים:

- קורלציה חיובית חלשה בינונית בין avg_rating_received למשתנה המטרה match

ככל שהמשתתף קיבל דירוגים גבוהים יותר, הסיכוי לmatch עולה, אך הקשר אינו חזק.

- קורלציה חיובית חלשה בין 3match_roll_mean ל-match המצביעה על השפעת ההיסטוריה

מצביע על השפעה מוגבלת של היסטוריית התאמות קודמות.

- קורלציה נמוכה בין age_diff ו-same_race למשתנה המטרה.

מה שמעיד כי משתנים אלו לבדם אינם מנבאים משמעותיים של התאמה

Correlation Heatmap

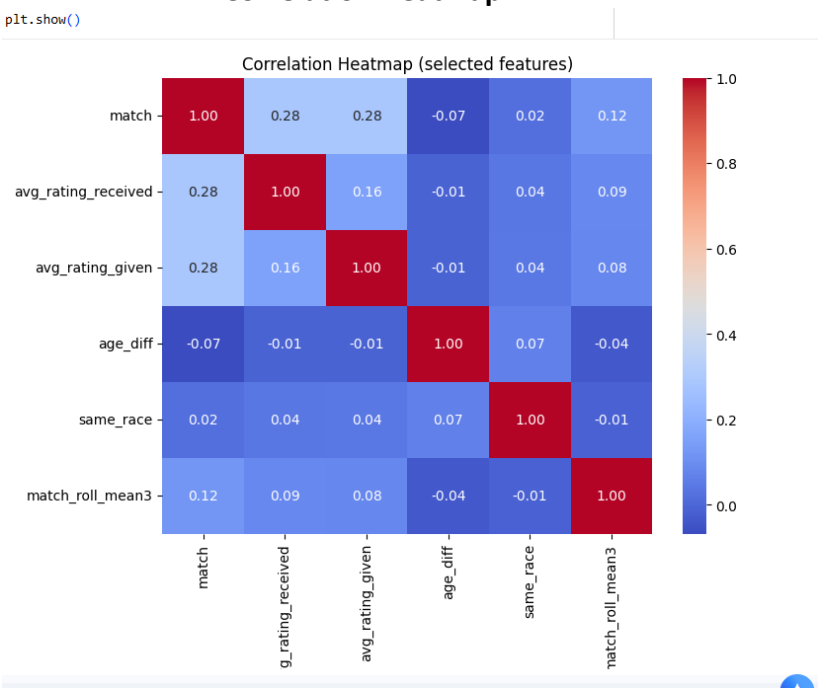

6. בניית המודלים

לצורך החיזוי נבחרו שלושה מודלים מתקדמים המבוססים על עצי החלטה, כאשר כל אחד מהם מציע יתרונות שונים מבחינת ביצועים, יציבות ויכולת הכללה.

6.1. Random Forest

תיאור:
אלגוריתם Ensemble המבוסס על בניית מספר רב של עצי החלטה באופן מקביל, תוך דגימה אקראית של תצפיות ומשתנים.

הפרמטרים שנבחרו:

- n_estimators = 500 – מספר העצים ביער
- max_depth = 8 – עומק מקסימלי של כל עץ
- min_samples_leaf = 15 – מספר מינימלי של דגימות בכל עלה
- min_samples_split = 30 – מספר מינימלי לפיצול צומת
- max_features = 'sqrt' – בחירה אקראית של משתנים בכל פיצול
- class_weight = 'balanced' – איזון בין הקטגוריות

רציונל:
הפרמטרים נבחרו במטרה לצמצם התאמת יתר (Overfitting) תוך שמירה על יכולת הכללה טובה.

```
# 4.3 Models + Rationale
# Random Forest
RandomForestClassifier(
    n_estimators=500,
    max_depth=8,
    min_samples_leaf=15,
    min_samples_split=30,
    max_features="sqrt",
    class_weight="balanced",
    random_state=42,
    n_jobs=-1
)
```

```
RandomForestClassifier
RandomForestClassifier(class_weight='balanced', max_depth=8,
                       min_samples_leaf=15, min_samples_split=30,
                       n_estimators=500, n_jobs=-1, random_state=42)
```

6.2. XGBoost

תיאור:

אלגוריתם Gradient Boosting מתקדם, הבונה עצים ברצף כך שכל עץ חדש מתקן את טעויות העצים הקודמים.

פרמטרים שנבחרו:

- n_estimators = 400
- learning_rate = 0.03
- max_depth = 3
- subsample = 0.8
- colsample_bytree = 0.8
- reg_alpha = 1.0
- reg_lambda = 3.0

רציונל:

שילוב של עומק עצים נמוך, קצב למידה איטי ורגולריזציה חזקה נועד ליצור מודל יציב ורובוסטי.

```
# XGBoost
XGBClassifier(
    n_estimators=400,
    learning_rate=0.03,
    max_depth=3,
    subsample=0.8,
    colsample_bytree=0.8,
    reg_alpha=1.0,
    reg_lambda=3.0,
    scale_pos_weight=(y_train==0).sum()/(y_train==1).sum(),
    eval_metric="logloss",
    random_state=42
)
```

```
XGBClassifier
XGBClassifier(base_score=None, booster=None, callbacks=None,
              colsample_bylevel=None, colsample_bynode=None,
              colsample_bytree=0.8, device=None, early_stopping_rounds=None,
              enable_categorical=False, eval_metric='logloss',
              feature_types=None, feature_weights=None, gamma=None,
              grow_policy=None, importance_type=None,
              interaction_constraints=None, learning_rate=0.03, max_bin=None,
              max_cat_threshold=None, max_cat_to_onehot=None,
              max_delta_step=None, max_depth=3, max_leaves=None,
              min_child_weight=None, missing=nan, monotone_constraints=None,
              multi_strategy=None, n_estimators=400, n_jobs=None,
```

6.3. LightGBM

תיאור:

אלגוריתם Gradient Boosting מהיר, המשתמש בגישת Leaf-wise growth לצורך יעילות חישובית גבוהה.

פרמטרים שנבחרו:

- n_estimators = 400
- learning_rate = 0.03
- num_leaves = 25
- min_data_in_leaf = 60
- feature_fraction = 0.8
- bagging_fraction = 0.8

רציונל:
המודל מותאם לעבודה עם נתונים מרובי משתנים תוך שליטה בסיבוכיות והפחתת Overfitting.

```
# LightGBM
LGBMClassifier(
    n_estimators=400,
    learning_rate=0.03,
    num_leaves=25,
    min_data_in_leaf=60,
    feature_fraction=0.8,
    bagging_fraction=0.8,
    class_weight="balanced",
    random_state=42
)
```

```
LGBMClassifier
LGBMClassifier(bagging_fraction=0.8, class_weight='balanced',
               feature_fraction=0.8, learning_rate=0.03, min_data_in_leaf=60,
               n_estimators=400, num_leaves=25, random_state=42)
```

6.4. חלוקת Train/Test ולידציה

Walk-Forward Cross Validation

בשל המבנה הזמני של הנתונים (waves), נעשה שימוש ב-Walk-Forward Validation במקום חלוקה אקראית:

- בכל איטרציה נתוני האימון כוללים את ה-waves הקודמים.
- נתוני הולידציה כוללים את ה-wave הבא ברצף.
- האימון מתחיל במינימום 6 waves.
- החלון מתקדם בכל צעד ומדמה חיזוי בזמן אמת.
  - שיטה זו מונעת Data Leakage ומספקת הערכה ריאליסטית יותר של ביצועי המודל.

```python
# 4.2 Walk-Forward Cross Validation
def walk_forward(df, waves, min_train=6):
    for i in range(min_train, len(waves)-1):
        train_w = waves[:i]
        val_w   = [waves[i]]
        yield (
            df["wave"].isin(train_w),
            df["wave"].isin(val_w)
        )
```

7. ניתוח חשיבות משתנים (Feature Importance)

לאחר אימון המודלים בוצע ניתוח חשיבות משתנים, במטרה להבין אילו גורמים משפיעים ביותר על החיזוי.

7.1. שיטות הניתוח

Gain-based Feature Importance (XGBoost, LightGBM)
מודד את הירידה הממוצעת בפונקציית האיבוד כתוצאה משימוש במשתנה מסוים.

Split Frequency (Random Forest)
מודד את מספר הפעמים שמשתנה שימש לפיצול בעצי ההחלטה.

7.2. המשתנים החשובים ביותר

דירוג	משתנה	משמעות
1	avg_rating_received	ממוצע הדירוגים שקיבל המשתתף
2	3match_roll_mean	ממוצע נע של הצלחות קודמות
3	attr_o	דירוג אטרקטיביות מצד בן/בת הזוג
4	1match_lag	תוצאת המפגש הקודם
5	int_corr	דמיון בתחומי עניין

תובנות מרכזיות:

- דירוגים הדדיים הם המנבאים החזקים ביותר.
- משתני זמן (Lag וממוצעים נעים) משפרים משמעותית את הדיוק.
- משתנים דמוגרפיים משפיעים פחות.

8. השוואת ביצועים והערכת דיוק

8.1. מדדי הערכה

מדד	הסבר
RMSE	שורש ממוצע השגיאות בריבוע
MAE	ממוצע הערך המוחלט של השגיאות
MAPE	אחוז השגיאה הממוצע
R^2	אחוז השונות המוסברת

למרות שמדובר בבעיה בינארית, מדדים רציפים חושבו על ההסתברויות שהמודלים מחזירים כדי להעריך את רמת הוודאות של החיזויים.

8.2. תוצאות השוואתיות

- **המודל המוביל – LightGBM**
  הציג את ערכי ה-RMSE הנמוכים ביותר ולכן סיפק את רמת הדיוק הגבוהה ביותר.

- **XGBoost ו-Random Forest**
  שניהם הציגו ביצועים טובים אך מעט נמוכים יותר. Random Forest נמצא רובוסטי יותר לרעש, בעוד XGBoost סיפק איזון טוב בין ביצועים למהירות.

	RMSE	MAE	MAPE (%)	R2
LightGBM	0.342697	0.217373	1.450081e+10	0.089379
XGBoost	0.360749	0.264136	1.990629e+10	-0.009087
RandomForest	0.400727	0.381787	3.053295e+10	-0.245131

9. ROC Curves - Receiver Operating Characteristic

גרף המציג את יכולת ההפרדה של מודל סיווג בינארי. הוא משווה בין:

- ציר Y (אנכי): TPR (True Positive Rate) - רגישות - כמה מהתאמות אמיתיות זוהו נכון
- ציר X (אופקי): FPR (False Positive Rate) - כמה "לא התאמות" זוהו בטעות כהתאמות

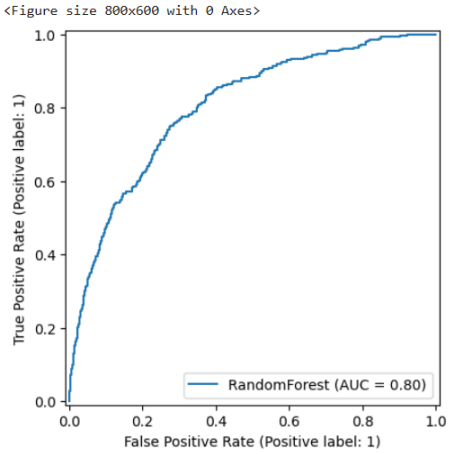

Random Forest AUC = 0.80

ביצועים: טובים

AUC של 0.80 = המודל נכון ב-80% מהמקרים

פרשנות:

- העקומה עולה מהר בהתחלה (זיהוי טוב של התאמות אמיתיות)
- יש איזון סביר בין זיהוי נכון למזעור שגיאות
- מודל יציב ואמין

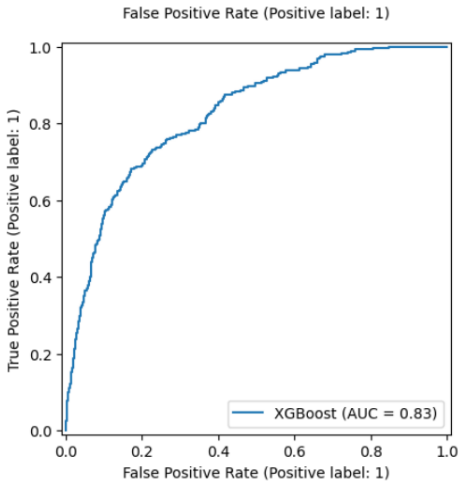

XGBoost AUC = 0.83

ביצועים: מצוינים - המודל הטוב ביותר
של 0.83 = המודל נכון ב-83% מהמקרים AUC

פרשנות:

- העקומה הכי קרובה לפינה השמאלית העליונה
- זיהוי מעולה של התאמות אמיתיות עם מעט מאוד שגיאות
- המודל המומלץ מבין השלושה.

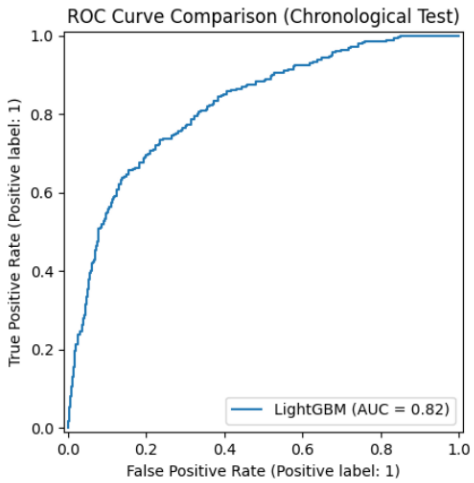

LightGBM AUC = 0.82

ביצועים: מצוינים
AUC של 0.82 = המודל נכון ב-82% מהמקרים

פרשנות:

- ביצועים כמעט זהים ל-XGBoost
- איזון מעולה בין מהירות לדיוק
- טוב מאוד לייצור (production) בגלל יעילות חישובית

מודל	AUC	מקום	הערה
Random Forest	0.80	3	פחות טוב , פחות דיוק
XGBoost	0.83	1	הטוב ביותר - יעילות , דייקנות.
LightGBM	0.82	2	טוב לייצור - מהיר יותר

10.Feature Importance Analysis

- Feature Importance - מודד כמה כל משתנה תורם לדיוק החיזוי של המודל. ככל שהערך גבוה יותר, המשתנה חשוב יותר להחלטה אם תהיה התאמה או לא.

10.1. RandomForest

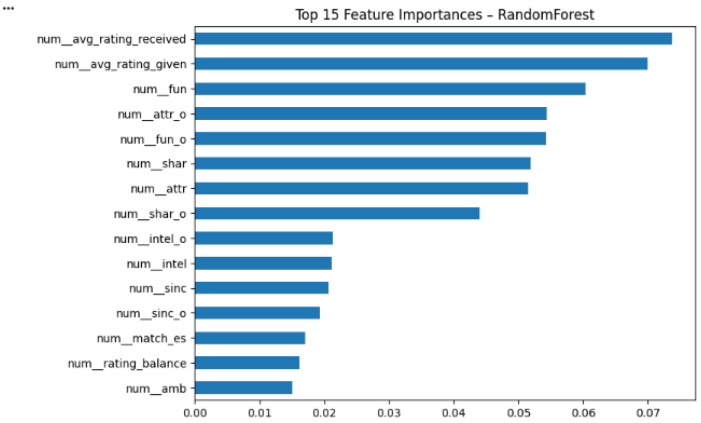

- נוסחה: דירוגים טובים שקיבלת + דירוגים טובים שנתת +כימיה והנאה הדדית=ההתאמה

Top 5 החשובים ביותר:

~0.07 **num_avg_rating_received**

- ממוצע הדירוגים שהמשתתף **קיבל** מאחרים
- **פירוש:** אם אנשים מעריכים אותך גבוה = סיכוי גבוה להתאמה

~0.065 **num_avg_rating_given**

- ממוצע הדירוגים שהמשתתף **נתן** לאחרים
- **פירוש:** אופי הדירוגים שאתה נותן משקף את הציפיות והסטנדרטים שלך

~0.06 **num_fun**

- דירוג "כיף" - כמה המפגש היה מהנה
- **פירוש:** כימיה חיובית ואווירה טובה חשובות

num_attr_o ~0.055

- דירוג אטרקטיביות מהצד השני
- **פירוש:** משיכה פיזית היא גורם משמעותי

num_like_o ~0.05

- דירוג "חיבוב כללי" מהצד השני
- **פירוש:** התרשמות כללית חיובית

10.2. <u>XGBoost</u>

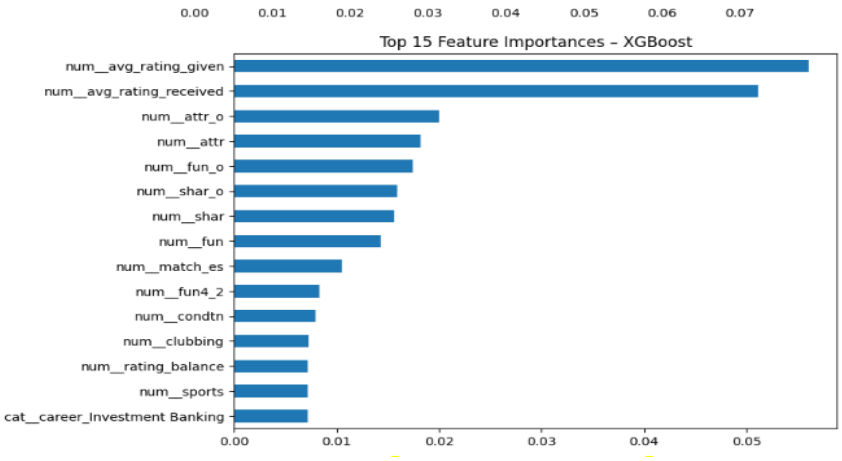

- נוסחה: הגישה שלך (איך אתה מדרג) + מה אחרים חושבים עליך = ההתאמה

<u>Top 5 החשובים ביותר:</u>

num_avg_rating_given ~0.065

ממוצע הדירוגים שהמשתתף נתן לאחרים (בכל המפגשים)

פירוש: אנשים שנותנים דירוגים גבוהים = יותר סיכוי להתאמה

num_avg_rating_received ~0.06

- ממוצע הדירוגים שהמשתתף קיבל מאחרים
- **פירוש:** אם אנשים מדרגים אותך גבוה = אתה אטרקטיבי ונעים

Num_attr_o ~0.03

- כמה הצד השני דירג אותך באטרקטיביות
- **פירוש:** אם השני חושב שאתה אטרקטיבי = הוא מעוניין בך

num_attr ~0.025

- כמה אתה דירגת את השני באטרקטיביות
- **פירוש:** אם אתה חושב שהשני אטרקטיבי = אתה מעוניין

Num_fun_o ~0.022

- כמה השני נהנה מהמפגש איתך
- **פירוש:** אם לשני היה כיף = הוא רוצה להמשיך

10.3. LightGBM

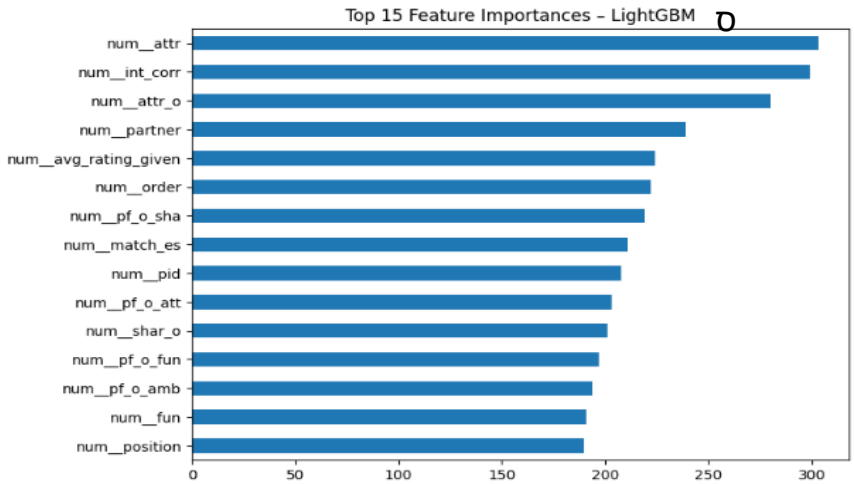

- נוסחה: אטרקטיביות פיזית + תחומי עניין משותפים = ההתאמה

Top 5 החשובים ביותר:

num_attr ~300

- **מה זה:** כמה אתה דירגת את השני באטרקטיביות
- **פירוש:** אם אתה חושב שהשני אטרקטיבי = סיכוי גבוה שתרצה התאמה

num_int_corr ~280

- **מה זה:** קורלציה בין תחומי העניין שלכם
- **פירוש:** תחביבים משותפים = חיבור עמוק יותר

~250 **num_attr_o**

- **מה זה:** כמה השני דירג אותך באטרקטיביות
- **פירוש:** אם השני חושב שאתה אטרקטיבי = הוא מעוניין

~230 **num_partner**

- **מה זה:** מזהה ייחודי של השותף במפגש
- **פירוש:** יש אנשים "פופולריים" שמקבלים הרבה התאמות

~220 **Num_avg_rating_given**

- **מה זה:** ממוצע הדירוגים שנתת לאחרים
- **פירוש:** אנשים נדיבים בדירוגים = יותר התאמות

11.מסקנות ודיון

מחקר זה הדגים את יכולתם של מודלים מתקדמים מבוססי עצי החלטה לחזות התאמות במפגשי Speed Dating ברמת דיוק גבוהה. הממצאים מספקים תובנות חשובות הן להבנה מדעית של משיכה בין-אישית והן לשיפור מערכות המלצה דיגיטליות.

11.1. <u>ממצאים מרכזיים</u>

- **עליונות מודל LightGBM**
המודל הציג את הביצועים הטובים ביותר, תודות ליעילות החישובית שלו וליכולתו לשלוט בסיבוכיות המודל תוך מניעת התאמת יתר (overfitting). הפרמטרים המותאמים אפשרו איזון מיטבי בין דיוק להכללה.

- **חשיבות הדירוגים ההדדיים**
דירוגי האטרקטיביות וההערכות ההדדיות בין המשתתפים התגלו כמנבאים החזקים ביותר. ממצא זה מדגיש את הדומיננטיות של הרושם הראשוני והכימיה המיידית בהצלחת מפגשים אישיים, בדומה לתופעות פסיכולוגיות מוכרות של "משיכה ממבט ראשון".

- **תרומת משתנים זמניים**
משתני Lag וממוצעים נעים שיפרו משמעותית את דיוק החיזוי. הממצא מעיד על כך שהיסטוריית ההצלחות והכישלונות של משתתף משפיעה על ביטחונו העצמי, התנהגותו וסיכויו העתידיים - תופעה המוכרת בפסיכולוגיה כ-"momentum effect".

- **השפעה מוגבלת של משתנים דמוגרפיים**
משתנים כמו הפרש גילאים והשתייכות לאותו גזע הראו השפעה נמוכה יחסית. זה מצביע על כך שהאינטראקציה האישית והכימיה הבין-אישית חזקות באופן משמעותי מגורמים דמוגרפיים סטטיים.

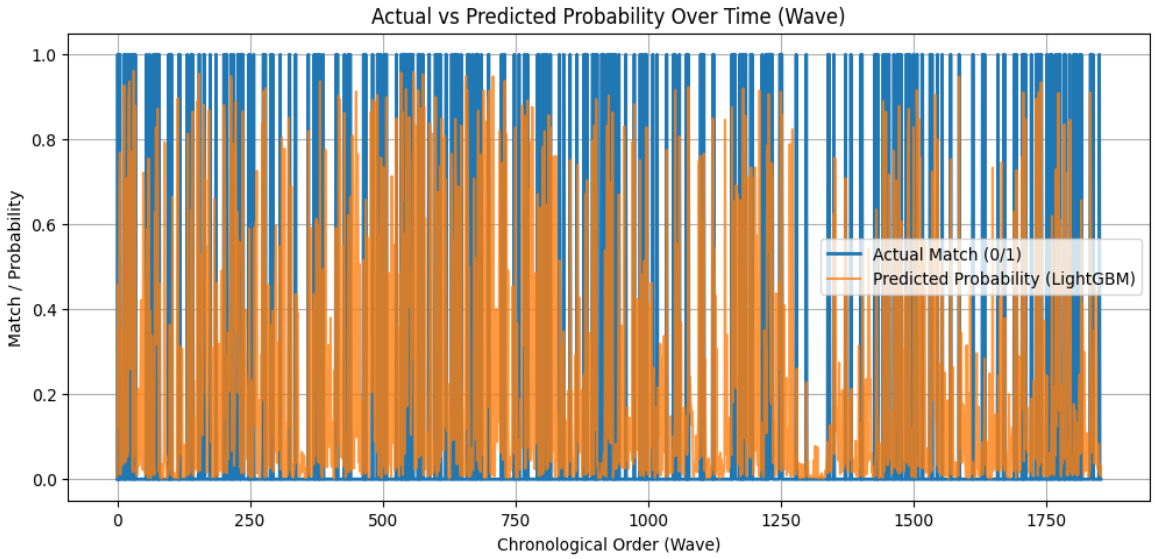

11.2. מגבלות המחקר

- **הגדרת ציר הזמן**
  השימוש ב-wave כציר זמן מהווה פשרה טכנית. למרות שזה מאפשר יישום של טכניקות ניתוח זמן, מדובר באירועים בדידים ולא בסדרת זמן רציפה אמיתית, מה שעשוי להגביל את עומק הניתוח הזמני.

- **חוסר איזון בקטגוריות**
  שיעור נמוך של התאמות (16.5% בלבד) יוצר אתגר מתודולוגי. חוסר איזון זה דורש טיפול מיוחד (class balancing) ועלול לגרום למודל להיות שמרני מדי בחיזוי התאמות, עם נטייה למזער False Positives.

- **מגבלות הכללה**
  הנתונים נאספו מאוכלוסייה אקדמית צעירה באוניברסיטת קולומביה. דפוסי ההתנהגות והעדפות ההיכרות עשויים להיות שונים באוכלוסיות אחרות מבחינת גיל, רקע תרבותי או סוציו-אקונומי, מה שמגביל את יכולת ההכללה של הממצאים.

- **היעדר מודלי Deep Learning**
  המחקר התמקד במודלים מבוססי עצים. יישום רשתות נוירונים עמוקות (LSTM, GRU) עשוי לחשוף תבניות מורכבות נוספות, במיוחד בזיהוי דפוסים זמניים ארוכי טווח שמודלים קלאסיים מתקשים ללכוד.

11.3. תרומה למחקר ולפרקטיקה

- **תרומה מדעית**
  המחקר מדגים את הערך של שילוב משתני זמן (Lag, Rolling averages) בבעיות סיווג שבהן ההקשר ההיסטורי רלוונטי. גישה זו ישימה גם לתחומים נוספים כמו ניתוח התנהגות צרכנים, חיזוי עזיבת לקוחות (churn prediction), וחיזוי הצלחה בלמידה מקוונת.

- **תרומה מעשית**
  הממצאים מספקים תובנות ישירות לשיפור אלגוריתמי המלצה באפליקציות היכרויות דיגיטליות. דגש על דירוגים הדדיים, מעקב אחר היסטוריית המשתמש, והתחשבות ב-momentum אישי יכולים להוביל למערכות המלצה מדויקות ויעילות יותר, ולשיפור שביעות רצון המשתמשים.